

붓꽃(Iris) 데이터 분석 및 시각화

품종별 특징을 수치와 그래프로 비교하고, 변수 사이의 관계를 해석한 결과 보고서

표본 수 150개 3개 품종이 각 50개씩 포함	측정 변수 4개 꽃받침/꽃잎의 길이와 너비	핵심 시각화 4종 막대, 산점도, 상자그림, 상관행렬
---	--------------------------------------	--

분석 목표

붓꽃 3개 품종(Setosa, Versicolor, Virginica)의 측정값을 비교하여 품종별 특징을 확인하고, 어떤 변수가 품종 구분에 유용한지 시각적으로 탐색한다.

데이터 출처: scikit-learn에 포함된 Iris 데이터셋. 총 150개 관측치이며 각 관측치는 꽃받침 길이/너비, 꽃잎 길이/너비를 cm 단위로 기록한다.

작성자: _____ 작성일: _____

01 데이터 설명과 분석 과정


Iris 데이터는 세 품종의 형태적 차이를 비교하기에 적합한 대표적인 분류 데이터다. 표본 수가 품종별로 동일하여 단순 비교에서 특정 품종의 표본 수가 지나치게 큰 문제도 없다.

변수	의미	단위
sepal length	꽃받침 길이	cm
sepal width	꽃받침 너비	cm
petal length	꽃잎 길이	cm
petal width	꽃잎 너비	cm
species	붓꽃 품종	범주형

분석 순서

Colab에서 수행한 분석 흐름


1. 데이터 불러오기 및 결측치 확인
2. 품종별 표본 수와 평균값 계산
3. 품종별 분포와 변수 간 관계 시각화
4. 상관관계 확인
5. 그래프를 바탕으로 특징과 의미 해석



해석: 세 품종의 표본 수가 모두 50개로 동일하다. 따라서 품종별 평균이나 분포를 비교할 때 표본 수 불균형에 따른 왜곡이 크지 않다.

각 품종별 측정값 평균을 계산하면 Setosa는 꽃잎이 매우 작고, Virginica는 전반적으로 큰 편이며, Versicolor는 두 품종 사이의 값을 보이는 경향이 확인된다.

품종	꽃받침 길이(cm)	꽃받침 너비(cm)	꽃잎 길이(cm)	꽃잎 너비(cm)
Setosa	5.01	3.43	1.46	0.25
Versicolor	5.94	2.77	4.26	1.33
Virginica	6.59	2.97	5.55	2.03




해석: 꽃받침 길이는 Setosa가 가장 짧고 Virginica가 가장 길다. Versicolor와 Virginica는 일부 구간에서 분포가 겹치므로 꽃받침 길이 하나만으로 두 품종을 완전히 구분하기는 어렵다.


핵심 관찰

평균값과 분포를 함께 보면 단순 평균만 보는 것보다 품종 간 겹침 정도까지 확인할 수 있다. 특히 Setosa는 여러 변수에서 비교적 뚜렷한 차이를 보인다.

꽃잎 길이와 꽃잎 너비를 산점도로 나타내면 품종별 군집이 뚜렷하게 형성된다. 특히 Setosa는 다른 두 품종과 거의 완전히 분리되어 보인다.



해석: 꽃잎 길이가 증가할수록 꽃잎 너비도 함께 증가하는 강한 양의 관계가 보인다. Setosa는 작은 꽃잎 영역에 모이고, Virginica는 큰 꽃잎 영역에 주로 위치한다. Versicolor는 중간 영역에 위치한다.



상관관계 해석: 꽃잎 길이와 꽃잎 너비의 상관계수는 약 0.96로 매우 높다. 즉 두 변수는 함께 커지는 경향이 강하다. 반면 꽃받침 너비는 다른 일부 변수와의 관계가 상대적으로 약하다.

분석 결과, 품종 구분에 가장 직관적으로 유용한 변수는 꽃잎 길이와 꽃잎 너비였다. 두 변수는 품종별 군집을 잘 드러내며 서로의 상관도 매우 높았다. 꽃받침 길이 역시 품종별 평균 차이는 존재하지만 Versicolor와 Virginica의 분포가 일부 겹쳤다.

관찰 1	세 품종은 각 50개 표본으로 균형 있게 구성되어 있다.
관찰 2	Setosa는 꽃잎 길이와 너비가 다른 품종보다 확연히 작다.
관찰 3	Virginica는 평균적으로 가장 큰 꽃잎과 긴 꽃받침을 보인다.
관찰 4	꽃잎 길이와 꽃잎 너비는 매우 강한 양의 상관관계를 가진다.

Google Colab 예시 코드

```
from sklearn.datasets import load_iris
import pandas as pd
import matplotlib.pyplot as plt

iris = load_iris(as_frame=True)
df = iris.frame
df['species'] = df['target'].map(dict(enumerate(iris.target_names)))

# 1) 품종별 평균
print(df.groupby('species')[iris.feature_names].mean())

# 2) 꽃잎 길이-너비 산점도
for name in iris.target_names:
    s = df[df['species'] == name]
    plt.scatter(s['petal length (cm)'], s['petal width (cm)'], label=name)
plt.xlabel('Petal length (cm)')
plt.ylabel('Petal width (cm)')
plt.legend()
plt.show()

# 3) 상관계수
print(df[iris.feature_names].corr())
```

제출용 한 줄 요약

Iris 데이터를 품종별로 비교한 결과, 꽃잎 길이와 너비가 품종 차이를 가장 뚜렷하게 보여 주며 두 변수 사이에도 강한 양의 상관관계가 확인되었다.

참고: 본 보고서는 scikit-learn 내장 Iris 데이터셋을 사용하여 작성하였다. 수치는 소수 둘째 자리까지 반올림하였다.